


- **İkili sınıflandırma (Binary Classification)**
- **Temel metin sınıflandırma  
örneği:Imdb**

# İkili sınıflandırma (Binary Classification)

- İkili sınıflandırma, verilerin iki sınıfa ayrılmasını içerir. Örneğin, bir müşterinin cinsiyet, yaş, yer vb. gibi bağımsız değişkenleri temel alarak belirli bir ürün alıp almadığı (Evet / Hayır) ikili sınıflandırma problemi olabilir.



# İkili sınıflandırma örneği: IMDB film incelemeleri

- Derin öğrenmeyi kullanarak film incelemelerinden pozitif veya negatif görüşler tahmin edilebilir.
- Büyük Film İnceleme Veri Kümesi (genellikle IMDB veri kümesi olarak adlandırılır) eğitim için 25.000 kutuplu yorum (iyi veya kötü) ve test için 25.000 kutuplu yorum içerir.
- Problem, yapılan bir yorumun olumlu veya olumsuz bir anlama sahip olup olmadığını belirlemektir.

# İkili sınıflandırma örneği: IMDB film incelemeleri

```
In [28]: from keras.datasets import imdb
```

```
In [29]: (train_data, train_labels), (test_data, test_labels)=imdb.load_data(num_words=10000)
```

```
In [30]: len(train_data)
```

```
Out[30]: 25000
```

```
In [31]: len(test_data)
```

```
Out[31]: 25000
```

```
In [32]: print(train_data[0])
```

```
[1, 14, 22, 16, 43, 530, 973, 1622, 1385, 65, 458, 4468, 66, 3941, 4, 173, 36, 256, 5, 25, 100, 43, 838, 112, 50, 670, 2, 9, 35, 480, 284, 5, 150, 4, 172, 112, 167, 2, 336, 385, 39, 4, 172, 4536, 1111, 17, 546, 38, 13, 447, 4, 192, 50, 16, 6, 147, 2025, 19, 14, 22, 4, 1920, 4613, 469, 4, 22, 71, 87, 12, 16, 43, 530, 38, 76, 15, 13, 1247, 4, 22, 17, 515, 17, 12, 16, 626, 18, 2, 5, 62, 386, 12, 8, 316, 8, 106, 5, 4, 2223, 5244, 16, 480, 66, 3785, 33, 4, 130, 12, 16, 38, 619, 5, 25, 124, 51, 36, 135, 48, 25, 1415, 33, 6, 22, 12, 215, 28, 77, 52, 5, 14, 407, 16, 82, 2, 8, 4, 107, 117, 5952, 15, 256, 4, 2, 7, 3766, 5, 723, 36, 71, 43, 530, 476, 26, 400, 317, 46, 7, 4, 2, 1029, 13, 104, 88, 4, 381, 15, 297, 98, 32, 2071, 56, 26, 141, 6, 194, 7486, 18, 4, 226, 22, 21, 134, 476, 26, 480, 5, 144, 30, 5535, 18, 51, 36, 28, 224, 92, 25, 104, 4, 226, 65, 16, 38, 1334, 88, 12, 16, 283, 5, 16, 4472, 113, 103, 32, 15, 16, 5345, 19, 178, 32]
```

```
In [33]: print(train_labels[0])
```

```
1
```

```
In [34]: print(train_labels[100])
```

```
0
```

# İkili sınıflandırma örneği: IMDB film incelemeleri

```
In [120]: word_index = imdb.get_word_index()
```

```
In [121]: word_index = {k:(v+3) for k,v in word_index.items()}
```

```
In [122]: reverse_word_index = dict([(value, key) for (key, value) in word_index.items()])
```

```
In [123]: str=[reverse_word_index.get(i, '?') for i in train_data[0]]
```

```
In [124]: print(str)
```

```
['?', 'this', 'film', 'was', 'just', 'brilliant', 'casting', 'location', 'scenery',  
'story', 'direction', "everyone's", 'really', 'suited', 'the', 'part', 'they', 'played',  
'and', 'you', 'could', 'just', 'imagine', 'being', 'there', 'robert', '?', 'is', 'an',  
'amazing', 'actor', 'and', 'now', 'the', 'same', 'being', 'director', '?', 'father',  
'came', 'from', 'the', 'same', 'scottish', 'island', 'as', 'myself', 'so', 'i', 'loved',  
'the', 'fact', 'there', 'was', 'a', 'real', 'connection', 'with', 'this', 'film', 'the',  
'witty', 'remarks', 'throughout', 'the', 'film', 'were', 'great', 'it', 'was', 'just',  
'brilliant', 'so', 'much', 'that', 'i', 'bought', 'the', 'film', 'as', 'soon', 'as', 'it',  
'was', 'released', 'for', '?', 'and', 'would', 'recommend', 'it', 'to', 'everyone', 'to',  
'watch', 'and', 'the', 'fly', 'fishing', 'was', 'amazing', 'really', 'cried', 'at', 'the',  
'end', 'it', 'was', 'so', 'sad', 'and', 'you', 'know', 'what', 'they', 'say', 'if', 'you',  
'cry', 'at', 'a', 'film', 'it', 'must', 'have', 'been', 'good', 'and', 'this',  
'definitely', 'was', 'also', '?', 'to', 'the', 'two', 'little', "boy's", 'that', 'played',  
'the', '?', 'of', 'norman', 'and', 'paul', 'they', 'were', 'just', 'brilliant', 'children',  
'are', 'often', 'left', 'out', 'of', 'the', '?', 'list', 'i', 'think', 'because', 'the',  
'stars', 'that', 'play', 'them', 'all', 'grown', 'up', 'are', 'such', 'a', 'big',  
'profile', 'for', 'the', 'whole', 'film', 'but', 'these', 'children', 'are', 'amazing',  
'and', 'should', 'be', 'praised', 'for', 'what', 'they', 'have', 'done', "don't", 'you',  
'think', 'the', 'whole', 'story', 'was', 'so', 'lovely', 'because', 'it', 'was', 'true',  
'and', 'was', "someone's", 'life', 'after', 'all', 'that', 'was', 'shared', 'with', 'us',  
'all']
```

# İkili sınıflandırma örneği: IMDB film incelemeleri

```
16 def vectorize_sequences(sequences, dimension=10000):
17     # Sıfırlardan oluşan, (len(sequences), dimension)
18     results = np.zeros((len(sequences), dimension))
19     for i, sequence in enumerate(sequences):
20         results[i, sequence] = 1.
21     return results
22
23 (train_data, train_labels), (test_data, test_labels) =
24 imdb.load_data(num_words=10000)
25
26 # Eğitim ve test verilerini vektöre dönüştür
27 x_train = vectorize_sequences(train_data)
28 x_test = vectorize_sequences(test_data)
29
30 # Etiketleri vektöre dönüştür
31 y_train = np.asarray(train_labels).astype('float32')
32 y_test = np.asarray(test_labels).astype('float32')
33
```

Sıfırlardan oluşan  
10000 elemanlı bir  
vektör oluştur.  
10000 kelimeden  
yorum içerisinde  
kullanılanları 1  
diğerlerini 0 yap

Kaynak: <https://github.com/fchollet/deep-learning-with-python-notebooks/blob/master/3.5-classifying-movie-reviews.ipynb>

# Veri setinin uygunlaştırılması

```
In [214]: train_data[0]
```

Out[214]:

[1,  
14,  
22,  
16,  
43,  
530,  
973,  
1622,  
1385,  
65,  
458,  
4468,  
66,  
3941,  
4,  
173,  
36,  
256,  
5,  
25,  
100,  
43,  
838,  
112,  
50,  
670,  
2,  
9,  
35,

```
In [262]: y=np.sort(train_data[0]).reshape(len(train_data[0]),1)
```

```
In [263]: y
```

Out[263]:

```
array([[1],  
       [2],  
       [2],  
       [2],  
       [2],  
       [2],  
       [4],  
       [4],  
       [4],  
       [4],  
       [4],  
       [4],  
       [4],  
       [4],  
       [4],  
       [4],  
       [4],  
       [5],  
       [5],  
       [5],  
       [5],  
       [5],  
       [5],  
       [5],  
       [6],  
       [6],  
       [7],  
       [7],  
       [8],  
       [8],  
       [8]])
```


```
In [269]: y=x_train[0].reshape(len(x_train[0]),1)
```

```
In [270]: y[0:50]
```

Out[270]:

[illegible]

# Ağ modelinin tanımlanması



```
36 model=models.Sequential()  
37  
38 model.add(layers.Dense(16,  
39                         activation='relu',  
40                         input_shape=(10000,)))  
41  
42 model.add(layers.Dense(16,  
43                         activation='relu'))  
44  
45 model.add(layers.Dense(1,  
46                         activation='sigmoid'))
```



# Optimizasyon parametreleri

- Kayıp (loss) fonksiyonu olarak mean\_squared\_error gibi bir fonksiyon kullanılabilir. Ağın çıkışı iki sınıfa ait bir olasılık belirteceği için binary\_crossentropy tercih edilmiştir.
- Burada binary\_accuracy ile eğitim sırasında doğruluk gözlenecektir.

```
52 model.compile(optimizer=optimizers.RMSprop(lr=0.001),  
53               loss='binary_crossentropy',  
54               metrics=['binary_accuracy'])  
55  
56 #model.compile(optimizer=optimizers.RMSprop(lr=0.001),  
57 #              loss=losses.binary_crossentropy,  
58 #              metrics=[metrics.binary_accuracy])
```

# Optimizasyon parametreleri

```
model.fit(x_train,  
          y_train,  
          epochs=20,  
          batch_size=500)
```

Doğrulama  
(Validation)  
yapılmadan  
eğitim.

```
1 x_validation = x_train[:5000]  
2 partial_x_train = x_train[5000:]  
3  
4 y_validation = y_train[:5000]  
5 partial_y_train = y_train[5000:]  
6  
7 history = model.fit(partial_x_train,  
8                     partial_y_train,  
9                     epochs=20,  
10                    batch_size=500,  
11                    validation_data=(x_validation, y_validation))
```

Eğitim sırasında her veri setini dolaşımda doğruluk ölçülebilir. Bu işlem eğitimde kullanılmayan örneklerle yapılacağı için eğitim setinden belirtilen sayıda örneğin doğrulama için ayrılması gerekir.

# Eğitimin gerçekleştirilmesi

```
20000/20000 [=====] - 4s 193us/step - loss: 0.0753 -  
binary_accuracy: 0.9750 - val_loss: 0.3715 - val_binary_accuracy: 0.8798  
Epoch 10/20  
20000/20000 [=====] - 4s 198us/step - loss: 0.0648 -  
binary_accuracy: 0.9794 - val_loss: 0.4183 - val_binary_accuracy: 0.8748  
Epoch 11/20  
20000/20000 [=====] - 5s 234us/step - loss: 0.0517 -  
binary_accuracy: 0.9856 - val_loss: 0.4532 - val_binary_accuracy: 0.8710  
Epoch 12/20  
20000/20000 [=====] - 4s 215us/step - loss: 0.0486 -  
binary_accuracy: 0.9857 - val_loss: 0.4601 - val_binary_accuracy: 0.8708  
Epoch 13/20  
20000/20000 [=====] - 4s 206us/step - loss: 0.0371 -  
binary_accuracy: 0.9900 - val_loss: 0.4971 - val_binary_accuracy: 0.8700  
Epoch 14/20  
20000/20000 [=====] - 4s 194us/step - loss: 0.0346 -  
binary_accuracy: 0.9901 - val_loss: 0.5306 - val_binary_accuracy: 0.8700  
Epoch 15/20  
20000/20000 [=====] - 4s 196us/step - loss: 0.0265 -  
binary_accuracy: 0.9935 - val_loss: 0.5627 - val_binary_accuracy: 0.8688  
Epoch 16/20  
20000/20000 [=====] - 4s 198us/step - loss: 0.0266 -  
binary_accuracy: 0.9930 - val_loss: 0.5886 - val_binary_accuracy: 0.8668  
Epoch 17/20  
20000/20000 [=====] - 4s 192us/step - loss: 0.0195 -  
binary_accuracy: 0.9953 - val_loss: 0.6267 - val_binary_accuracy: 0.8676  
Epoch 18/20  
20000/20000 [=====] - 4s 205us/step - loss: 0.0171 -  
binary_accuracy: 0.9962 - val_loss: 0.6483 - val_binary_accuracy: 0.8704  
Epoch 19/20  
20000/20000 [=====] - 4s 208us/step - loss: 0.0136 -  
binary_accuracy: 0.9972 - val_loss: 0.6812 - val_binary_accuracy: 0.8648  
Epoch 20/20  
20000/20000 [=====] - 4s 193us/step - loss: 0.0114 -  
binary_accuracy: 0.9972 - val_loss: 0.7083 - val_binary_accuracy: 0.8674
```

In [299]:

- fit() fonksiyonu ile eğitim gerçekleştirildiğinde yandaki gibi her bir iterasyonda optimizasyonun durumu hakkında bilgiler yazdırılmaktadır.

# train history

```
In [304]: history.params
Out[304]:
{'batch_size': 500,
 'epochs': 20,
 'steps': None,
 'samples': 20000,
 'verbose': 1,
 'do_validation': True,
 'metrics': ['loss', 'binary_accuracy', 'val_loss', 'val_binary_accuracy']}
```

```
In [305]: history.history['loss']
```

```
Out[305]:
[0.4691212125122547,
 0.2696381252259016,
 0.20318141616880894,
 0.16699168421328067,
 0.13623715490102767,
 0.118472003005445,
 0.10028673037886619,
 0.08507895935326815,
 0.07529340004548431,
 0.06475454457104206,
 0.05171188111416995,
 0.04857624201104045,
 0.037075738934800026,
 0.034565999545156954,
 0.026503147394396364,
 0.026570425694808365,
 0.019534876430407168,
 0.017106045153923333,
 0.013624661194626242,
 0.011400983622297644]
```

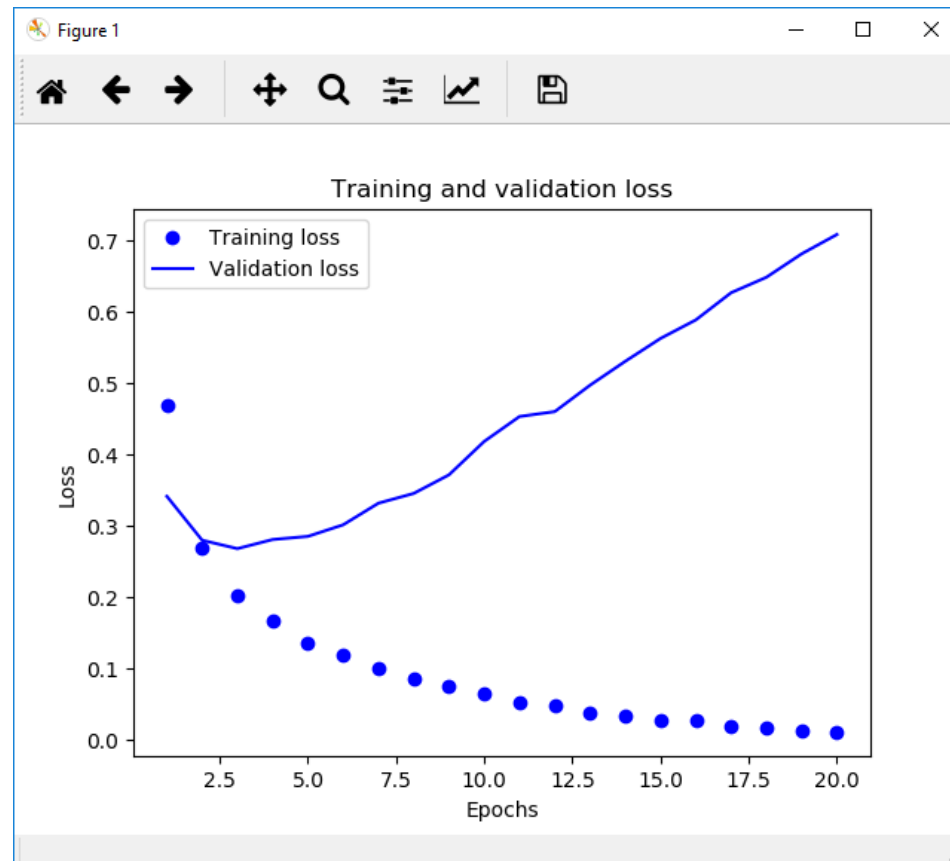
```
In [306]:
```

Eğitim sonunda fit()  
ile döndürülen  
history nesnesinden  
optimizasyon  
parametrelerinin  
iterasyona (epoch)  
bağlı değişimi  
incelenebilir.

Yanda, kayıp (loss)  
fonksiyonunun  
iterasyona bağlı  
değerleri  
listelenmiştir.

# Grafik çizimleri (History)

```
7 history_dict = history.history
8 loss_values = history_dict['loss'] # grafik 1
9 val_loss_values = history_dict['val_loss'] # grafik 2
0 epochs = range(1, len(loss_values) + 1) # yatay eksen: 1..20
1 plt.plot(epochs, loss_values, 'bo', label='Training loss')
2 plt.plot(epochs, val_loss_values, 'b', label='Validation loss')
3 plt.title('Training and validation loss')
4 plt.xlabel('Epochs')
5 plt.ylabel('Loss')
6 plt.legend()
7 plt.show()
```



# Test

```
In [320]: test_loss, test_acc = model.evaluate(x_test,y_test)
25000/25000 [=====] - 4s 161us/step
```

```
In [321]: print(test_acc)
0.84808
```

```
In [322]: print(test_loss)
0.8149055649638176
```

- Eğitim setinde %86 civarında elde edilen başarımın test setinde %84 civarına düştüğü görülüyor.

# Deneyler

- Katman sayısını azalt veya artır: 1 katman veya 3 katman
- Katmanlarda kullanılan birim sayısını artır:32, 48 veya 64
- Loss fonksiyonunu değiştir: mse
- Aktivasyon fonksiyonlarını değiştir: Relu yerine tanh kullan
- Optimizasyon yöntemini değiştir: Adam

<https://github.com/fchollet/deep-learning-with-python-notebooks/blob/master/3.5-classifying-movie-reviews.ipynb>