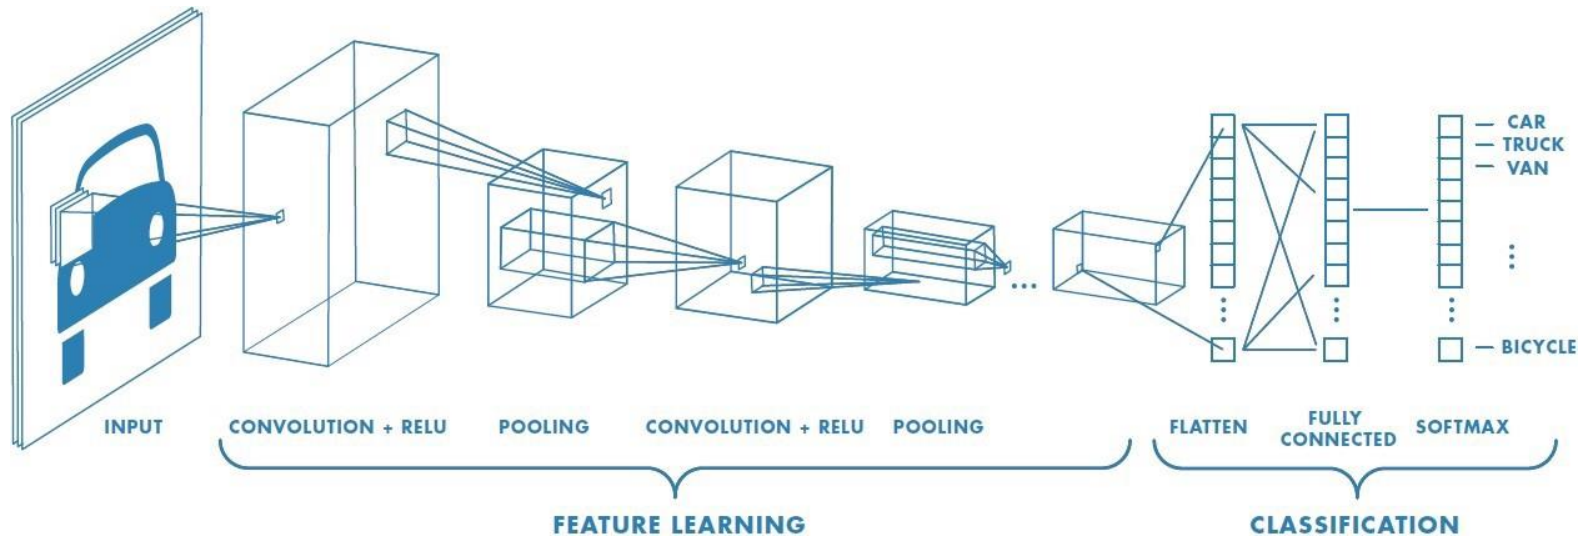


- **Convolutional Neural Networks (convnets,CNN)**
 - **2D convolution**
 - **Padding**
 - **Stride**
 - **Dilation**
 - **Pooling**
 - **Flatten**

Convolutional Neural Networks



- Bir Evrişimsel Sinir Ağı (ConvNet / Convolutional neural networks -CNN), bir girdi görüntüsünü alıp, görüntüdeki çeşitli görünüşleri/nesneleri birbirinden ayırabilen Derin Öğrenme algoritmasıdır.
- Evrişimli sinir ağları, temel olarak görüntüleri sınıflandırmak (örneğin gördüklerini isimlendirmek), benzerlikle kümelemek (fotoğraf arama) ve sahnelerde nesne tanıma yapmak için kullanılan derin yapay sinir ağlarıdır.

2D convolution

0	0	0	0	0	0
0	105	102	100	97	96
0	103	99	103	101	102
0	101	98	104	102	100
0	99	101	106	104	99
0	104	104	104	100	98

Image Matrix

Kernel Matrix

0	-1	0
-1	5	-1
0	-1	0


320				

Output Matrix

$$\begin{aligned} &0 * 0 + 0 * -1 + 0 * 0 \\ &+ 0 * -1 + 105 * 5 + 102 * -1 \\ &+ 0 * 0 + 103 * -1 + 99 * 0 = 320 \end{aligned}$$

**Convolution with horizontal and
vertical strides = 1**

2D convolution



padding

3_0	3_1	2_2	1	0
0_2	0_2	1_0	3	1
3_0	1_1	2_2	2	3
2	0	0	2	2
2	0	0	0	1

12	12	17
10	17	19
9	6	14

Kernel:

$$\begin{pmatrix} 0 & 1 & 2 \\ 2 & 2 & 0 \\ 0 & 1 & 2 \end{pmatrix}$$

- Kernelin kenarlara geldiği hesaplamalar ihmal edilebilir.
- $W \times H$ boyutlu bir görüntü 3×3 kernel ile konvolüsyon işlemi sonucu $(W-2) \times (H-2)$ boyutlu bir görüntüye dönüşür.
- Benzer şekilde 5×5 kernel için görüntü $(W-4) \times (H-4)$ boyutlu bir görüntüye dönüşür.

Keras: padding=valid

padding

Çıkış görüntüsünün boyutunu sabit tutmak için kenar dolgulama yapılabilir.

0	0	0	0	0	0	0
0	60	113	56	139	85	0
0	73	121	54	84	128	0
0	131	99	70	129	127	0
0	80	57	115	69	134	0
0	104	126	123	95	130	0
0	0	0	0	0	0	0

Kernel

0	-1	0
-1	5	-1
0	-1	0


114				

Keras: padding= same


Stride (adım büyüklüğü)

Konvolüsyon işlemi genel de 1 piksel adımlarla gerçekleştirilir.

7 x 7 Input Volume




5 x 5 Output Volume




Ancak çıkış görüntüsünü seyrelmek için daha büyük adımlar kullanılabilir.

7 x 7 Input Volume




3 x 3 Output Volume




Konvolüsyon 2 adım aralıklarla gerçekleştirildiğinde çıkış görüntüsü yaklaşık yarıya düşer

Geniřleme oranı (Dilation rate)

- Conv2D sınıfının `dilation_rate` parametresi, dilate konvolüsyon için dilation oranını kontrol eden bir 2'li tam sayıdır.
- Dilate konvolüsyon, yukarıda şekilde gösterildiđi gibi, yalnızca tanımlanan boşluklarla giriş görüntüsüne uygulanan konvolüsyon işlemidir.




Pooling (birleştirme)




Pooling (birleştirme)

- Max Pooling





Pooling (birleştirme)


- Average Pooling



Flatten (düzleştirme)



Örnek: mnist veri seti



Örnek: mnist veri seti

```
8 from keras import layers
9 from keras import models
10
11 model = models.Sequential()
12 model.add(layers.Conv2D(32,
13                         (3, 3),
14                         activation='relu',
15                         input_shape=(28,28, 1)))
16
17 model.add(layers.MaxPooling2D((2, 2)))
18
19 model.add(layers.Conv2D(64,
20                         (3, 3),
21                         activation='relu'))
22
23 model.add(layers.MaxPooling2D((2, 2)))
24
25 model.add(layers.Conv2D(64,
26                         (3, 3),
27                         activation='relu'))
28
29
30 model.add(layers.Flatten())
31
32 model.add(layers.Dense(64, activation='relu'))
33
34 model.add(layers.Dense(10, activation='softmax'))
35
36
37 model.summary()
```

Örnek: mnist veri seti

Layer (type)	Output Shape	Param #
conv2d_36 (Conv2D)	(None, 26, 26, 32)	320
max_pooling2d_3 (MaxPooling2D)	(None, 13, 13, 32)	0
conv2d_37 (Conv2D)	(None, 11, 11, 64)	18496
max_pooling2d_4 (MaxPooling2D)	(None, 5, 5, 64)	0
conv2d_38 (Conv2D)	(None, 3, 3, 64)	36928
flatten_4 (Flatten)	(None, 576)	0
dense_7 (Dense)	(None, 64)	36928
dense_8 (Dense)	(None, 10)	650
Total params: 93,322		
Trainable params: 93,322		
Non-trainable params: 0		

Örnek: mnist veri seti

Kodun devamı:

```
39 from keras.datasets import mnist
40 from keras.utils import to_categorical
41
42 (train_images, train_labels), (test_images, test_labels) =\
43     mnist.load_data()
44
45 train_images = train_images.reshape((60000, 28, 28, 1))
46 train_images = train_images.astype('float32') / 255
47 test_images = test_images.reshape((10000, 28, 28, 1))
48 test_images = test_images.astype('float32') / 255
49 train_labels = to_categorical(train_labels)
50 test_labels = to_categorical(test_labels)
51
52 model.compile(optimizer='rmsprop',
53               loss='categorical_crossentropy',
54               metrics=['accuracy'])
55
56 model.fit(train_images,
57           train_labels,
58           epochs=5,
59           batch_size=64)
60
61 test_loss, test_acc = model.evaluate(test_images, test_labels)
62 print("test_acc=", test_acc)
```


Örnek: mnist veri seti

```
Epoch 1/5
60000/60000 [=====] - 45s 747us/step - loss: 0.1628 - acc: 0.9492
Epoch 2/5
60000/60000 [=====] - 45s 751us/step - loss: 0.0479 - acc: 0.9851
Epoch 3/5
60000/60000 [=====] - 55s 911us/step - loss: 0.0330 - acc: 0.9896
Epoch 4/5
60000/60000 [=====] - 52s 873us/step - loss: 0.0249 - acc: 0.9923
Epoch 5/5
60000/60000 [=====] - 48s 808us/step - loss: 0.0197 - acc: 0.9942
10000/10000 [=====] - 3s 293us/step
test_acc= 0.9915
```